

Aplicação de Técnicas de Machine Learning na Precificação de Peças Usinadas da aeronáutica

Gabriel Almeida de Faria
Jardel Manoel Vieira
João Pedro Flaúsinio de Lima
Victor Hugo Reis Olegario

Professor:
Felipe A. N. Verri

RESUMO

O presente trabalho tem como objetivo aplicar técnicas de aprendizado de máquina à estimativa de preços de peças usinadas, com o intuito de automatizar etapas do processo de elaboração de orçamentos e reduzir a variabilidade gerada por análises manuais e reduzir o tempo de resposta. Para isso, foi utilizada uma base de dados contendo 522 observações de peças em alumínio, com variáveis físicas facilmente mensuráveis, como peso da matéria-prima, peso final da peça, quantidade de cavaco removido e comprimento. Após análises exploratórias e testes com diferentes algoritmos, o modelo que apresentou melhor desempenho foi o Random Forest, aplicado de forma segmentada por faixas de preço ($\leq$ R\$ 5.000 e $>$ R\$ 5.000), resultando em valores reduzidos de erro absoluto e percentual em comparação ao modelo linear inicial.

Os resultados demonstram que essas variáveis físicas possuem relação direta com o custo de usinagem e que modelos de machine learning podem servir como ferramenta eficaz para estimativas preliminares de preço. A solução foi integrada em uma aplicação web desenvolvida em Streamlit, permitindo sua utilização prática por analistas de orçamento e clientes. O estudo confirma a viabilidade da abordagem e estabelece fundamentos para futuras expansões envolvendo atributos geométricos CAD 3D e variáveis de processo.

Palavras-chave: aprendizado de máquina; Random Forest; precificação; usinagem; estimativa de custos; data science.

1 INTRODUÇÃO

A estimativa de custos de usinagem é um desafio recorrente em indústrias metalmeccânicas, pois envolve múltiplos fatores — desde o tipo de material e geometrias das peças até tempos de ciclo e complexidade operacional. A elaboração manual de orçamentos é demorada e sujeita a variações entre orçamentistas.

Nesse contexto, o presente estudo propõe o desenvolvimento de um modelo para previsão automatizada de preços de peças usinadas, utilizando técnicas de machine learning e princípios de data science. O objetivo principal é demonstrar como o uso de dados históricos de produção e orçamentos pode permitir a construção de um modelo preditivo confiável, reduzindo o tempo de cotação e aumentando a precisão da precificação.

O trabalho foi conduzido segundo a metodologia CRISP-DM (Cross Industry Standard Process for Data Mining), conforme orienta Verri (2024), e complementado por práticas ágeis de desenvolvimento baseadas no Scrum, garantindo organização das etapas e aproveitamento das competências individuais dos membros do grupo.

2 FUNDAMENTAÇÃO TEÓRICA

O avanço das técnicas de machine learning tem impulsionado a automação de processos analíticos em domínios industriais, incluindo a estimação de custos de manufatura e, em especial, os processos de usinagem. Segundo Verri (2024), o aprendizado de máquina é um processo indutivo, no qual o modelo identifica padrões nos dados históricos e aprende relações estatísticas capazes de generalizar para novas observações.

No entanto, diferentes algoritmos apresentam desempenhos distintos dependendo da natureza da base de dados, da variabilidade dos atributos e do grau de não linearidade. No presente estudo, embora a regressão linear múltipla seja tradicionalmente utilizada em aplicações industriais, verificou-se que seu desempenho foi limitado para a modelagem do preço de peças usinadas. Isso ocorre porque o custo de usinagem depende de relações complexas, não lineares e muitas vezes interativas entre variáveis físicas, parâmetros operacionais e características geométricas, o que viola pressupostos centrais da regressão linear, como linearidade e relação proporcional entre variáveis.

Diante dessas limitações, optou-se por explorar algoritmos supervisionados não lineares baseados em árvores de decisão, em especial Random Forest e XGBoost. Essas abordagens são especialmente indicadas quando há indícios de não linearidade e quando o conjunto de dados possui variabilidade significativa, como observado no presente caso.

3 METODOLOGIA

3.1 ESTRUTURA DO CRISP-DM

Para conduzir o projeto de forma estruturada e alinhada às boas práticas de ciência de dados, foi adotado o modelo CRISP-DM. Cada uma de suas etapas foi aplicada de maneira prática ao problema de precificação de peças usadas, garantindo rastreabilidade das decisões e reprodutibilidade dos resultados.

I. Compreensão do Negócio

O desafio central foi automatizar e padronizar a elaboração de orçamentos. O processo manual dependia de conhecimento tácito, gerando inconsistências e prazos longos. Objetivo: criar um modelo preditivo capaz de estimar o preço de uma peça com base em características físicas mensuráveis.

II. Compreensão dos Dados

A base utilizada contém 522 registros de peças de alumínio, com variáveis relacionadas ao peso da matéria-prima (peso_mp), peso final (peso_peca), quantidade de cavaco (cavaco), comprimento (comprimento) e preço (preco). A análise exploratória identificou forte correlação entre cavaco e preco.

III. Preparação dos Dados

Foram realizadas etapas de limpeza, padronização e seleção de atributos.

Variáveis ausentes foram removidas, unidades de medida corrigidas e as colunas cavaco, peso_peca e comprimento foram mantidas como preditoras principais, reduzindo a colinearidade e simplificando o modelo.

IV. Modelagem

Diferentes abordagens supervisionadas foram testadas: Regressão Linear, Random Forest e XGBoost. A regressão linear apresentou baixo desempenho, indicando que as relações entre as variáveis físicas e o preço da peça são não lineares, assimétricas e influenciadas por múltiplas interações.

O modelo que apresentou melhor desempenho foi o Random Forest Regressor, devido às suas características: captura relações não lineares; é robusto a outliers e ruídos;

funciona bem com datasets pequenos e desbalanceados; exige poucos hiperparâmetros para boa performance

Além disso, foram treinados modelos separados para duas faixas de preço ($\leq R\$ 5.000$ e $> R\$ 5.000$), reduzindo o impacto de valores extremos e melhorando o ajuste do modelo. A modelagem foi implementada em Python usando scikit-learn, com 600 árvores e pré-processamento baseado em imputação por mediana.

V. Avaliação

A performance dos modelos foi analisada seguindo as orientações do livro de Filipe Verri (2024). A metodologia de validação buscou garantir capacidade de generalização, detecção de overfitting e aderência aos objetivos de negócio.

Metodologia de Validação

A validação do modelo seguiu práticas recomendadas de data science:

1. Divisão em treino e teste: Os dados foram divididos em um conjunto de treino e outro de teste, assegurando que o modelo fosse avaliado em dados que nunca havia visto. Essa separação reduz o risco de overfitting e permite medir a capacidade real de generalização.

2. Uso de métricas adequadas ao problema de regressão: Foram utilizadas as métricas recomendadas por Verri (2024) para problemas de previsão numérica:

- o R^2
- o MAE
- o RMSE
- o MAPE (%)

3. Validação segmentada (stratified validation): Como a base apresentava forte heterogeneidade, especialmente em relação às faixas de preço (≤ 5.000 e > 5.000 reais), foi aplicada validação segmentada, treinando e testando modelos em cada faixa. Isso reduziu o impacto de valores extremos e melhorou a análise de desempenho por subgrupos.

4. Comparação entre modelos: O processo de validação também envolveu a comparação estruturada entre diferentes algoritmos: Regressão Linear, Random Forest e XGBoost.

5. Validação cruzada: Em alguns experimentos, foi empregada validação cruzada (k-fold) para quantificar variação no desempenho e prevenir conclusões baseadas em divisões específicas da base.

Assim, a metodologia de validação adotada neste estudo se baseia na divisão treino-teste, avaliação

quantitativa por métricas recomendadas, validação estratificada e comparação entre algoritmos.

VI. Implantação

Os resultados foram exportados para planilha Excel, permitindo uso imediato em estimativas internas. A etapa seguinte prevê a integração com uma interface web para geração automática de orçamentos, transformando o modelo em um produto de ciência de dados, conforme o conceito de data product de Verri (2024).

3.2 METODOLOGIA ÁGIL – SCRUM

Para garantir a organização das atividades e o gerenciamento, adotou-se a metodologia ágil Scrum.

As tarefas foram organizadas em um product backlog e distribuídas em sprints semanais. Gabriel atuou como Product Owner, sendo responsável pela priorização das tarefas e acompanhamento dos resultados, enquanto os demais membros do grupo desempenharam o papel de Developers, responsáveis pelas etapas de coleta, tratamento e modelagem dos dados. Essa estrutura permitiu o desenvolvimento iterativo do projeto, assegurando revisões rápidas e integração contínua entre as etapas do processo de data science.




Figura 1. Estrutura membros do Scrum e Trello para backlog

4 COLETA E DESCRIÇÃO DOS DADOS

A base de dados utilizada contém 522 registros de peças usinadas, cada uma com as seguintes colunas:

Quadro 1. Dicionário de variáveis

Coluna	Descrição
PN	Identificação única da peça
preco	Valor real do orçamento (R\$)
peso_mp	Peso do material bruto (kg)
peso_pec	Peso final da peça (kg)
cavaco	Volume de material removido (diferença entre pesos)
comprimento	Comprimento da peça (mm)

Durante o entendimento inicial, observou-se que as variáveis *peso_pec*, *cavaco* e *comprimento* possuem

correlação positiva com o preço final, indicando que peças maiores e com mais remoção de material tendem a apresentar custo de usinagem mais elevado.




Figura 2. Mapa de correlação das variáveis

5 TRATAMENTO E PREPARAÇÃO DOS DADOS

O tratamento dos dados envolveu:

- Conversão dos valores numéricos com vírgulas decimais para ponto flutuante;
- Remoção de linhas incompletas;
- Criação de nova variável derivada $cavaco = peso_mp - peso_pec$;
- Normalização de unidades e checagem de inconsistências.
- Aplicação de log nas variáveis com exceção do preço.

Após o pré-processamento, a base ficou pronta para a etapa de modelagem, garantindo consistência e compatibilidade com os pacotes estatísticos em Python.

6 MODELAGEM

A etapa de modelagem teve como foco identificar qual algoritmo seria capaz de capturar de forma mais precisa a relação entre as variáveis independentes e o preço das peças usinadas. Diferentes modelos supervisionados foram avaliados com base em testes empíricos, análises de desempenho e validação sistemática.

6.1 TESTES INICIAIS COM MODELOS LINEARES

Modelos simples devem ser utilizados nas primeiras iterações do ciclo de modelagem, para estabelecer uma linha de base e validar hipóteses iniciais. Assim, foi implementada uma Regressão Linear Múltipla para verificar a existência de relações lineares entre as variáveis.

Embora interpretável, o modelo apresentou baixo desempenho, com R^2 negativo e erros elevados, evidenciando que: o problema possui relações não lineares; a distribuição dos preços é fortemente assimétrica; existem interações complexas entre as variáveis; os dados apresentam faixas de valores muito distintas. Dessa forma, a regressão linear foi descartada como modelo principal de predição.

6.2 ADOÇÃO DE ALGORITMOS NÃO LINEARES BASEADOS EM ÁRVORES

Após os testes iniciais, foram avaliados dois algoritmos capazes de lidar com padrões não lineares: **Random Forest Regressor** e **XGBoost Regressor**

Ambos são amplamente utilizados em problemas de precificação industrial, devido à sua capacidade de capturar interações entre variáveis. Em especial, o **Random Forest** demonstrou excelente desempenho com baixa configuração e estabilidade superior em bases pequenas e heterogêneas.

O XGBoost apresentou resultados satisfatórios, porém menos consistentes, principalmente devido ao pequeno número de amostras e à sensibilidade a hiperparâmetros.

6.3 SEGMENTAÇÃO POR FAIXAS DE PREÇO

Durante a análise exploratória, identificou-se forte heterogeneidade no conjunto de dados: **491 peças** com preço $\leq$ R\$ 5.000 e **32 peças** com preço $>$ R\$ 5.000

Essa diferença gerava viés no ajuste do modelo único. Para mitigar o problema, optou-se por treinar dois modelos Random Forest independentes, um para cada faixa de preço. Essa abordagem atuou como uma forma de *stratified modeling*, aumentando a precisão e reduzindo o efeito de outliers.

7 VALIDAÇÃO

A etapa de validação buscou avaliar a capacidade dos modelos de generalizar para novas observações, conforme orientado pela fase *Evaluation* do CRISP-DM e pelas recomendações metodológicas de Verri (2024), que enfatizam a separação entre dados de treino e teste e o uso de múltiplas métricas de erro para uma análise robusta.

7.1 METODOLOGIA DE VALIDAÇÃO

A validação foi conduzida em três níveis complementares:

(1) Validação treino–teste (holdout): A base completa de 522 amostras foi dividida em 80% para treino (418 registros) e 20% para teste (105 registros), garantindo que os modelos fossem avaliados em dados nunca vistos.

(2) Teste com múltiplos algoritmos: Foram avaliados três algoritmos supervisionados:

- Regressão Linear
- Random Forest Regressor
- XGBoost Regressor

O objetivo foi estabelecer um modelo baseline (linear) e comparar com modelos mais robustos.

(3) Validação segmentada por faixas de preço

Devido à forte heterogeneidade da base, adotou-se uma validação estratificada em duas faixas:

- Faixa 0: peças até R\$ 5.000 (pequenas e homogêneas)
- Faixa 1: peças acima de R\$ 5.000 (itens especiais, grandes ou complexos)

Isso reduz viés de distribuição e melhora a interpretação dos erros dentro de cada grupo.

7.2 RESULTADOS NUMÉRICOS

Os resultados após a divisão correta entre treino e teste foram os seguintes:

Base completa: Random Forest foi o melhor modelo global, com melhor equilíbrio entre R^2 , MAE e RMSE.

MODELO	R^2	MAE	RMSE	MAPE
RANDOM FOREST	0.6946	742,9	1971,1	45,4%
XGBOOST	0.6794	776,6	2019,6	50,1%
LINEAR	-2.4822	1.738	6.656	92,8%

Faixa 0 — até R\$ 5.000: XGBoost foi o melhor nessa faixa, indicando boa capacidade de capturar pequenas variações.

MODELO	R^2	MAE	RMSE	MAPE
XGBOOST	0.581	442,3	713,4	49,8%
LINEAR	0.521	502	762	58%
RANDOM FOREST	0.353	538,9	886,7	65%

Faixa 1 — acima de R\$ 5.000: XGBoost e Random Forest tiveram desempenho muito próximo, com leve vantagem do XGBoost em erro absoluto e percentual.

MODELO	R^2	MAE	RMSE	MAPE
XGBOOST	0.443	3.484	5.499	31,29%
RANDOM FOREST	0.455	3.890	5.437	31,99%
LINEAR	0.453	2.859	5.449	20,17%*

7.3 ANÁLISE DOS MAIORES ERROS

Os maiores erros ocorreram predominantemente na faixa acima de R\$ 5.000, onde as peças apresentam grandes

variações de dimensão, geometrias incomuns, alto peso e cavaco e ausência de operações adicionais não registradas (chanfro, furação profunda, tempo de usinagem, quantidade de furos ou rasgos etc.). Isso explica a alta variabilidade e reforça a necessidade futura de variáveis de processo e CAD 3D.

7.4 DISCUSSÃO DOS RESULTADOS

Os experimentos mostraram que a regressão linear foi insuficiente, confirmando a hipótese inicial, o modelo linear não capturou a não-linearidade.

Random Forest é o melhor modelo para a base completa. Isso ocorreu porque ele lida bem com não-linearidade, reduz impacto de outliers por agregação de árvores, funciona bem com poucas features.

XGBoost foi superior nas faixas segmentadas, principalmente maior sensibilidade em regiões densas ($\leq$ R\$ 5.000) e melhor ajuste em regiões esparsas ($>$ R\$ 5.000). O comportamento segmentado confirmou que o modelo ideal depende da faixa de preço.

Pesquisas recentes como Yoo & Kang (2020) e Manufacturing Cost Estimation (2023) obtêm MAPE entre 7% e 15% ao utilizar: modelos CAD 3D, redes neurais profundas e dados de processo (avanço, velocidade, tempo de corte). Em comparação, nossos modelos apresentam MAPE entre 31% e 65%, o que é esperado considerando a ausência de variáveis geométricas, ausência de parâmetros de usinagem e dataset reduzido.

7.5 CONCLUSÃO DA VALIDAÇÃO

A validação demonstrou que Random Forest é o melhor modelo para a base completa; XGBoost apresenta melhor desempenho nas faixas segmentadas; A segmentação por preço melhora substancialmente a capacidade preditiva; O modelo é adequado como PoC e como base para evolução futura, mas ainda distante das soluções de estado-da-arte baseadas em CAD 3D + deep learning.

8 IMPLANTAÇÃO DO MODELO

A fase de implementação teve como objetivo transformar o modelo preditivo desenvolvido em um sistema efetivamente utilizável pelos analistas e clientes que necessitam elaborar orçamentos. Para isso, foi construída uma aplicação web utilizando o Streamlit, permitindo que o modelo fosse disponibilizado como um Data Product, acessível de forma simples e direta. A solução foi publicada no Streamlit Cloud e passou a ser acessível em ambiente web.

8.1 ARQUITETURA GERAL DA APLICAÇÃO

A arquitetura da solução foi estruturada de acordo com as recomendações de Verri (2024) para fase de implantação, nas quais o modelo deve ser disponibilizado em um sistema funcional, acessível e reproduzível. Esse tipo de entrega corresponde ao conceito moderno de Data Product, no qual o modelo de machine learning é incorporado a uma aplicação operacional que permite seu uso contínuo. A aplicação foi organizada em três módulos principais: Predição Individual, Predição em Lote e Sobre o Modelo. Essa separação permite que diferentes perfis de usuários utilizem o sistema conforme suas necessidades. A aplicação está disponível em ambiente online no endereço: <https://lr-pecas-app-yx4hs5.streamlit.app/>

8.2 INTERFACE DE PREDIÇÃO INDIVIDUAL

A interface de predição individual foi desenvolvida para permitir que o usuário insira manualmente os valores de entrada relacionados à peça a ser precificada. Para cada variável são apresentados campos numéricos com indicação clara de unidade de medida, garantindo precisão na interpretação e reduzindo erros de preenchimento.

Além dos campos de entrada, a página inclui botões de ajuste incremental, explicações adicionais via tooltips e exemplos rápidos de peças pequena, média e grande.

Figura 3. Página web para predição

8.3 PREDIÇÃO EM LOTE

A aplicação também oferece a funcionalidade de predição em lote, na qual o usuário pode carregar uma planilha Excel contendo um conjunto de peças a serem precificadas.

8.4 MOTOR DE PREVISÃO

O motor de predição é composto pelo modelo Random Forest treinado de forma segmentada em duas faixas de preço: peças com valor até R\$ 5.000 e peças acima desse valor. Esse processo ocorre de maneira automática no backend: ao receber os valores de entrada, o sistema determina a faixa à qual a peça pertence, seleciona o modelo treinado especificamente para aquele grupo e realiza o pré-processamento necessário antes de calcular a previsão.

8.5 RELAÇÕES DE RAZÃO ENTRE FEATURES

Durante o fluxo interno de inferência, o backend calcula automaticamente relações de razão entre as variáveis de entrada, como:

- cavaco / peso_mp
- peso_peca / peso_mp
- cavaco / comprimento

Essas razões capturam proporções relacionadas ao processo de usinagem, como eficiência de remoção de material, relação entre forma e massa, e complexidade geométrica relativa. A inclusão dessas variáveis derivadas melhora a capacidade de generalização do modelo e reduz a dependência da escala dos dados, permitindo previsões mais robustas mesmo quando há grande variação no tamanho e peso das peças. Esse processamento é totalmente automatizado e ocorre apenas no backend, sem necessidade de manipulação manual por parte do usuário.

8.6 INTEGRAÇÃO COM O MODELO TREINADO

A integração entre o sistema e o modelo de machine learning ocorre por meio do carregamento de arquivos serializados em formato .pkl. O Streamlit executa o pipeline completo de inferência, incluindo carregamento do modelo, pré-processamento das entradas, escolha da faixa de preço, aplicação do algoritmo correto e retorno do valor previsto.

8.7 REGISTRO E TELEMETRIA TÉCNICA

Para aprimorar continuamente o sistema, o backend registra anonimamente informações de uso, como valores de entrada, faixa aplicada e valor previsto. Esses dados não incluem qualquer identificação sensível, mas permitem monitorar padrões de utilização, identificar casos fora do comportamento esperado e revelar lacunas na base de treinamento original.

9 CONCLUSÃO

O estudo demonstrou que é possível automatizar e padronizar o processo de precificação de peças usinadas utilizando técnicas de machine learning. Após análises exploratórias, segmentações por faixa de preço e comparação entre múltiplos algoritmos, o modelo que apresentou melhor desempenho foi o Random Forest treinado de forma segmentada.

Os resultados demonstram que atributos físicos básicos possuem relação direta com o custo de fabricação e podem ser usados como preditores efetivos para estimativas iniciais de preço. A solução proposta alcançou valores de erro compatíveis com o objetivo de automatizar etapas preliminares do orçamento, reduzindo tempo, dependência de conhecimento tácito e inconsistências entre analistas.

Além disso, a implementação do modelo como aplicação web interativa evidencia a viabilidade de transformar o algoritmo em um Data Product, permitindo seu uso direto por equipes técnicas e clientes.

Embora os modelos mais avançados da literatura, baseados em CAD 3D e deep learning, alcancem desempenhos superiores, a presente solução cumpre seu papel enquanto baseline robusto, interpretável, de baixo custo computacional e adequado para empresas que estão iniciando sua jornada de digitalização. Os resultados obtidos validam a proposta e estabelecem um caminho para evoluções futuras.

10 TRABALHOS FUTUROS

A partir dos resultados obtidos, diversas direções podem ser exploradas para aprimorar a precisão. As oportunidades de evolução se concentram principalmente em três dimensões: expansão de variáveis, aumento da complexidade algorítmica e integração operacional.

Um primeiro avanço é incorporar variáveis geométricas extraídas diretamente de modelos CAD 3D, conforme demonstrado por Yoo & Kang (2020). A extração de features como cavidades, canais, raios, tolerâncias, superfícies críticas e complexidade geométrica permite capturar nuances do projeto que não são observáveis pelas variáveis físicas simples utilizadas no presente estudo. Além disso, técnicas de Explainable AI (XAI) aplicadas a esses atributos poderiam fornecer interpretações visuais sobre quais regiões da peça contribuem para o aumento do custo.

Outra linha de evolução envolve a ampliação da base de dados para incluir parâmetros de processo de usinagem, conforme sugerido no estudo Manufacturing Cost Estimation Based on the Machining Process and Deep-Learning Method (2023). Variáveis como velocidade de corte, avanço por rotação, potência da máquina, tempo efetivo de operação, material da ferramenta e tipo de operação (desbaste, acabamento, furação etc.) tendem a aumentar significativamente a capacidade preditiva dos modelos. A inclusão dessas variáveis abriria espaço para uso de algoritmos mais complexos, como arquiteturas de deep learning.

Essas melhorias têm potencial para transformar o modelo atual em um sistema completo, escalável e compatível com o estado da arte em estimativa de custos industriais.

11 REFERÊNCIAS

- **VERRI, F.** *Data Science Project: Metodologia e Aplicações Reais*. São José dos Campos: ITA Press, 2024.
- **HAN, J.; KAMBER, M.; PEI, J.** *Data Mining: Concepts and Techniques*. 3rd ed. San Francisco: Morgan Kaufmann, 2012.
- **JAMES, G.; WITTEN, D.; HASTIE, T.; TIBSHIRANI, R.** *An Introduction to Statistical*

Learning: with Applications in R. 2nd ed. New York: Springer, 2021.

- **KUHN, M.; JOHNSON, K.** *Feature Engineering and Selection: A Practical Approach for Predictive Models.* Boca Raton: CRC Press, 2019.
- **YOO, B.; KANG, S.** *Explainable Artificial Intelligence for Manufacturing Cost Estimation and Machining*

Feature Visualization. Procedia CIRP, v. 93, p. 1134-1139, 2020.
DOI: 10.1016/j.procir.2020.03.132

- **MANUFACTURING COST ESTIMATION BASED ON THE MACHINING PROCESS AND DEEP-LEARNING METHOD.** *Journal of Manufacturing Processes*, v. 82, p. 780-791, 2023.
DOI: 10.1016/j.jmapro.2023.03.014